Universidad de Murcia
Facultad de Informática

Cuantificación longitudinal de la progresión del Alzheimer con MRI

Pipeline de procesamiento de imagen médica
sobre el dataset OASIS-2

Asignatura: Procesamiento de Imagen en Medicina
Curso académico: 2025–2026

Grupo:

Álvaro Espejo Martínez
Javier Hernández Rosique
Raúl Sánchez Ibáñez

Murcia, abril de 2026

Resumen

Se presenta un pipeline completo y reproducible de procesamiento de imagen médica para la cuantificación longitudinal de la progresión del Alzheimer, desarrollado sobre el dataset público OASIS-2 (150 sujetos, 77 pares de visitas longitudinales, edades 60–96 años). El pipeline integra: (i) preprocesamiento robusto por percentiles; (ii) registro intra-sujeto rígido con evaluación cuantitativa en cuatro métricas —NCC +104 %, MSE −52 % tras registro— y comparativa experimental frente a transformaciones afín y deformable (Demons); (iii) segmentación ventricular clásica por umbral adaptativo con correcciones de consistencia longitudinal (*histogram matching* y prior espacial), validada frente a MedSAM con *prompt* automático (Dice medio 0.158); y (iv) registro inter-sujeto al atlas MNI-ICBM152 con propagación de la máscara hipocampal Harvard-Oxford para estimación del volumen de tejido hipocampal bilateral.

El pipeline procesa correctamente 76 de 77 pacientes (98.7 %). La comparativa de métodos de registro confirma al rígido como la opción óptima para estudios longitudinales frente a Demons, que mejora las métricas fotométricas un 4 % en NCC a costa de triplicar el tiempo de cómputo y riesgo de absorber la atrofia real. La segmentación umbral muestra una varianza de 24–31 %/año entre grupos, superior a la señal de atrofia esperada (2–8 %/año), lo que impide obtener correlaciones significativas con CDR y MMSE ($\rho = -0{,}054$, $p = 0{,}641$) y constituye la limitación principal del trabajo. El análisis hipocampal sobre 50 pacientes muestra la viabilidad del enfoque atlas: el paciente Demented de referencia exhibe una tasa de −7,5 %/año, coherente con la literatura, aunque el tamaño muestral impide generalizaciones estadísticas.

Palabras clave: Alzheimer, MRI longitudinal, OASIS-2, registro de imagen, segmentación ventricular, MedSAM, atlas MNI, atrofia cerebral.

Índice

Resumen **1**

1. Introducción **4**

1.1. Contexto clínico 4

1.2. MRI como biomarcador estructural 4

1.3. Motivación y planteamiento del proyecto 5

2. Estado del arte **5**

2.1. Registro de imágenes cerebrales 5

2.2. Segmentación de ventrículos e hipocampo 6

2.3. Modelos de segmentación fundacionales: MedSAM 6

3. Objetivos y metodología **6**

3.1. Objetivos 6

3.2. Dataset: OASIS-2 7

3.3. Diagrama del pipeline 8

3.4. Preprocesamiento robusto (P01/P02) 8

3.5. Registro intra-sujeto (P03) 8

3.6. Comparativa de métodos de registro 9

3.7. Segmentación de ventrículos laterales (P04) 9

3.8. Segmentación con MedSAM 9

3.9. Registro inter-sujeto al atlas MNI 10

3.10. Análisis longitudinal y validación clínica 10

4. Resultados **11**

4.1. Calidad del registro intra-sujeto 11

4.2. Comparativa rígido / afín / Demons 12

4.3. Segmentación ventricular: clásica vs. MedSAM 13

4.4. Análisis longitudinal: tasa de atrofia ventricular 14

4.5. Volumen hipocampal (atlas MNI) 15

4.6. Validación clínica 16

5. Conclusiones y vías futuras **17**

5.1. Hallazgos principales 17

5.2. Limitaciones 18

5.3. Vías futuras 18

Anexo: Contribución individual **21**

1. Introducción

1.1. Contexto clínico

La enfermedad de Alzheimer (EA) es la forma más prevalente de demencia, representando entre el 60 % y el 70 % de todos los casos. Según la Organización Mundial de la Salud, más de 55 millones de personas la padecen en todo el mundo, cifra que se prevé alcance los 139 millones en 2050 debido al envejecimiento poblacional [1]. En España, se estima que más de 800 000 personas están afectadas, con un coste sociosanitario superior a los 24 000 millones de euros anuales.

Desde el punto de vista neuropatológico, la EA se caracteriza por la acumulación progresiva de placas de beta-amiloide extracelulares y ovillos de proteína tau hiperfosforilada intracelulares. Estos procesos desencadenan una cascada inflamatoria que conduce a la pérdida neuronal masiva, comenzando en el hipocampo y la corteza entorrinal, y extendiéndose posteriormente a regiones neocorticales de asociación [1]. La consecuencia macroscópica observable mediante imagen por resonancia magnética (MRI) es una atrofia cerebral progresiva que se manifiesta como reducción volumétrica de estructuras subcorticales —principalmente el hipocampo— y dilatación secundaria de los ventrículos laterales.

La escala *Clinical Dementia Rating* (CDR) es el estándar clínico para estadificar la gravedad de la demencia, desde CDR = 0 (cognitivamente normal) hasta CDR = 3 (demencia grave), pasando por CDR = 0.5 (deterioro cognitivo leve o MCI). El *Mini-Mental State Examination* (MMSE) proporciona una medida cuantitativa del rendimiento cognitivo global (0–30 puntos). Ambas escalas se usan habitualmente como referencia para validar biomarcadores de imagen.

1.2. MRI como biomarcador estructural

La MRI estructural T1 permite cuantificar de forma no invasiva los cambios volumétricos cerebrales asociados a la neurodegeneración [2]. Dos estructuras han demostrado ser especialmente sensibles a la progresión del Alzheimer:

Hipocampo. Su atrofia es el biomarcador de imagen más temprano y específico de la EA: puede detectarse años antes de que los síntomas clínicos sean evidentes [2]. Una tasa de atrofia hipocampal superior al 3–4 % anual en individuos con MCI predice con alta especificidad la conversión a demencia.

Ventrículos laterales. Su dilatación es una consecuencia indirecta de la pérdida de volumen del parénquima cerebral circundante. Aunque menos específica que la atrofia hipocampal en fases tempranas, la tasa de dilatación ventricular anual correlaciona fuertemente con el estadio de demencia en cohortes longitudinales y es más fácil de segmentar automáticamente por su alto contraste en T1 [2].

El análisis longitudinal —comparar el mismo paciente en dos o más instantes temporales— es clave para distinguir el envejecimiento normal del patológico. Una sola imagen no permite separar ambos procesos; es la *tasa de cambio* la que resulta diagnósticamente relevante. Esto requiere un registro preciso entre visitas para que las diferencias de volumen observadas sean reales y no artefactos de posicionamiento.

1.3. Motivación y planteamiento del proyecto

El presente proyecto aborda el diseño e implementación de un pipeline de procesamiento de imagen médica para cuantificar objetivamente la progresión del Alzheimer a partir de la cohorte pública OASIS-2, que incluye 150 sujetos con múltiples visitas de seguimiento. El pipeline integra técnicas de las prácticas de la asignatura (preprocesamiento, registro, segmentación) con aportaciones propias: normalización robusta por percentiles, comparativa experimental entre métodos de registro, validación cruzada entre segmentación clásica y modelo fundacional MedSAM [3], corrección de escala entre visitas mediante *histogram matching*, y registro inter-sujeto al atlas MNI-ICBM152 para extracción automática del volumen hipocampal.

La hipótesis central del proyecto es que **la tasa de atrofia ventricular e hipocampal anual, calculada a partir de imágenes MRI T1 longitudinales, es significativamente mayor en pacientes con Alzheimer activo que en individuos cognitivamente sanos, y correlaciona con el grado de deterioro clínico medido por CDR y MMSE**. Verificar esta hipótesis sobre datos reales, con un pipeline reproducible y experimentalmente validado, constituye el objetivo central del trabajo.

2. Estado del arte

2.1. Registro de imágenes cerebrales

El registro de imagen es el proceso de alinear geométricamente dos o más adquisiciones para que las mismas coordenadas espaciales correspondan a la misma estructura anatómica. En neuroimagen longitudinal es imprescindible: sin alineación previa, las diferencias de posición y orientación de la cabeza entre visitas se confunden con cambios de volumen reales.

Los métodos de registro se clasifican por los grados de libertad (DOF) de la transformación [4]. El **registro rígido** (6 DOF: 3 traslaciones + 3 rotaciones) es el más conservador y el más apropiado para estudios longitudinales intra-sujeto, ya que no modifica la forma del cerebro. El **registro afín** (12 DOF) añade escala y cizallamiento, capturando diferencias globales de tamaño entre adquisiciones. Los métodos **deformables**, como el algoritmo de Demons [5] o SyN (ANTs), aplican campos de deformación densos vóxel a vóxel, consiguiendo mejor concordancia local a costa de potencialmente deformar estructuras que no han cambiado realmente, lo que los hace menos adecuados para cuantificar atrofia longitudinal [6].

La métrica de similitud más empleada en registro multimodal o con diferencia de intensidades entre sesiones es la **Información Mutua de Mattes**, una estimación estocástica de la información mutua basada en histogramas conjuntos que es robusta a diferencias de contraste entre adquisiciones. Studholme et al. [7] demostraron que la *Normalized Mutual Information* (NMI) es invariante al solapamiento parcial de las imágenes, siendo preferible a la IM estándar cuando los campos de visión difieren entre sesiones, como ocurre en OASIS-2.

2.2. Segmentación de ventrículos e hipocampo

La segmentación automática de estructuras cerebrales en MRI T1 ha evolucionado desde métodos basados en umbral hasta soluciones basadas en atlas y redes neuronales profundas.

Los métodos **por umbral** explotan el alto contraste del líquido cefalorraquídeo (CSF, hipointenso en T1) frente al parénquima cerebral. Son computacionalmente eficientes pero sensibles a variaciones de intensidad entre adquisiciones, lo que compromete la consistencia longitudinal si no se aplica ninguna normalización de escala entre visitas.

Los métodos **basados en atlas** —como FreeSurfer [6] o FSL FIRST— registran un atlas anatómico anotado al espacio del paciente y propagan las etiquetas. FreeSurfer es el estándar de referencia para volumetría cortical y subcortical en estudios de Alzheimer, pero requiere varias horas por sujeto y no es viable en entornos con tiempo de cómputo limitado. El atlas MNI-ICBM152 [8] combinado con el atlas Harvard-Oxford [9] proporciona máscaras subcorticales de alta resolución —incluyendo hipocampo bilateral— como alternativa más rápida para extracción de ROI.

Los métodos de **aprendizaje profundo** supervisados (nnU-Net, DeepMedic) alcanzan resultados comparables a FreeSurfer en ventrículos e hipocampo con tiempos de inferencia de segundos, pero requieren conjuntos de entrenamiento anotados que no siempre están disponibles para estructuras específicas.

2.3. Modelos de segmentación fundacionales: MedSAM

Segment Anything Model (SAM) es un modelo fundacional de segmentación de propósito general entrenado sobre más de un billón de máscaras. Su arquitectura basada en Vision Transformer (ViT) acepta *prompts* geométricos —puntos, cajas delimitadoras o máscaras parciales— para guiar la segmentación sin necesidad de reentrenamiento.

Ma et al. [3] desarrollaron **MedSAM**, una adaptación de SAM con *fine-tuning* sobre más de un millón de pares imagen-máscara de 11 modalidades médicas (incluyendo MRI cerebral). MedSAM supera al SAM original en imagen médica y obtiene resultados competitivos frente a modelos supervisados específicos de dominio en tareas de segmentación cerebral, sin requerir anotaciones propias del dataset a segmentar.

Una limitación relevante de MedSAM —y de SAM en general— es que opera sobre cortes 2D. En volumetría 3D, la segmentación debe aplicarse corte a corte y los resultados pueden ser inconsistentes entre planos adyacentes. En este trabajo se emplea MedSAM con un *prompt* de caja delimitadora derivado automáticamente de la segmentación clásica, eliminando la necesidad de anotación manual y constituyendo una aportación propia del pipeline.

3. Objetivos y metodología

3.1. Objetivos

El proyecto persigue los siguientes objetivos concretos:

1. Implementar un pipeline reproducible de preprocesamiento y registro rígido intra-sujeto sobre los 77 pares longitudinales de OASIS-2.
2. Evaluar cuantitativamente la calidad del registro mediante cuatro métricas de similitud y comparar experimentalmente tres métodos (rígido, afín y deformable Demons).
3. Segmentar automáticamente los ventrículos laterales con un método clásico basado en umbral y validar la segmentación cruzándola con MedSAM usando *prompt* automático.
4. Calcular la tasa de atrofia ventricular anual sobre los 77 pacientes, garantizando consistencia longitudinal mediante *histogram matching* y prior espacial derivado de V1.
5. Estimar el volumen hipocampal bilateral mediante registro inter-sujeto al atlas MNI-ICBM152 y medición de tejido dentro del ROI propagado.
6. Validar los biomarcadores de imagen correlacionándolos con las escalas clínicas CDR y MMSE mediante tests estadísticos.

3.2. Dataset: OASIS-2

OASIS-2 (*Open Access Series of Imaging Studies — Longitudinal*) [10] es una cohorte pública de 150 sujetos de entre 60 y 96 años con entre 2 y 5 sesiones de MRI separadas al menos un año. Cada sesión incluye de 3 a 4 adquisiciones T1 en formato Analyze 7.5 (`.hdr/.img`) con resolución de $256 \times 256 \times 128$ vóxeles y espaciado de 1 mm isotrópico.

Los metadatos clínicos se distribuyen como un fichero CSV con los campos: ID de sujeto, edad, sexo, años de educación, dominancia manual, grupo clínico (*Nondemented*, *Demented* o *Converted*), CDR, MMSE, eTIV (*estimated Total Intracranial Volume*), nWBV y campo *MR Delay* (días desde la primera visita). De los 150 sujetos, **77 presentan un par de visitas V1/V2 con imagen disponible**, que son los utilizados en el análisis longitudinal.

Nota sobre calidad del dato. El campo *MR Delay* toma valor 0 tanto en V1 como frecuentemente en V2, lo que impediría estimar el intervalo temporal entre visitas a partir de él. Para evitar tasas de atrofia artificialmente extremas, se usa la **diferencia de edad** (en años, registrada en el CSV con resolución de 1 año) como proxy del intervalo entre visitas, con un mínimo de 0.5 años.

El dataset se distribuye bajo licencia Creative Commons Attribution 4.0 (CC BY 4.0) y está disponible en Kaggle bajo el perfil `nadiatriki/oasis-2-longitudinal-study`.

3.3. Diagrama del pipeline

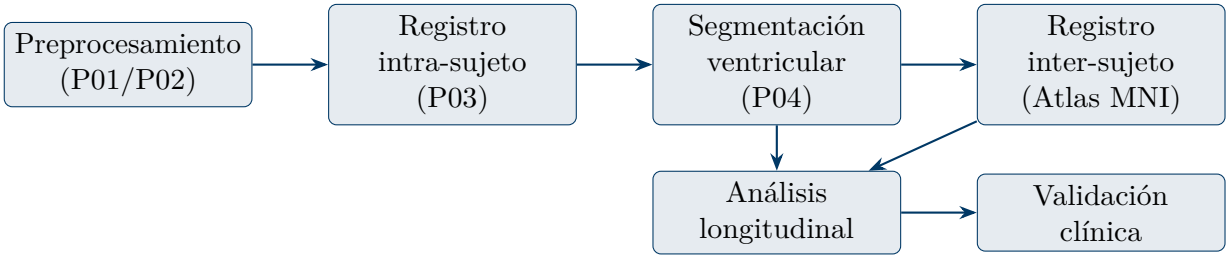

Figura 1: Diagrama del pipeline completo.

3.4. Preprocesamiento robusto (P01/P02)

Las imágenes T1 de OASIS-2 tienen rangos de intensidad absolutos muy variables entre sujetos y sesiones. Una normalización Min-Max estándar es sensible a valores extremos (*outliers* de intensidad por artefactos de adquisición): basta un único vóxel muy brillante para comprimir todo el rango útil hacia valores bajos.

La solución adoptada es la **normalización robusta por percentiles**: se recorta el 1 % inferior y superior de la distribución de intensidades del volumen 3D y se mapea el rango residual $[p_1, p_{99}]$ linealmente a $[0, 1]$. Esto elimina *outliers* sin descartar información anatómica y produce histogramas comparables entre sujetos, condición necesaria para que los umbrales de segmentación sean transferibles.

3.5. Registro intra-sujeto (P03)

El objetivo es alinear V2 al espacio de V1 para que las diferencias de volumen observadas entre visitas correspondan a cambios reales y no a variabilidad de posicionamiento. Se emplea un **registro rígido** (6 DOF: traslación + rotación) implementado con SimpleITK (`Euler3DTransform`), con los siguientes componentes:

- **Métrica**: Información Mutua de Mattes (50 intervalos de histograma, 15 % de muestreo aleatorio). Robusta frente a diferencias de contraste entre sesiones.
- **Optimizador**: *Regular Step Gradient Descent* ($\alpha = 1{,}0$, paso mínimo 10^{-4}, 200 iteraciones).
- **Inicialización**: `CenteredTransformInitializer` por momentos, que centra las imágenes antes de optimizar y evita mínimos locales por alineación inicial errónea.
- **Interpolación**: lineal para la imagen registrada; vecino más próximo (*nearest neighbor*) para máscaras binarias, preservando los valores discretos.

La calidad del registro se evalúa mediante cuatro métricas calculadas sobre un paciente de referencia antes y después de la alineación: MSE, NCC (*Normalized Cross-Correlation*), SSIM (*Structural Similarity Index* [11]) y NMI (*Normalized Mutual Information* [7]).

3.6. Comparativa de métodos de registro

Para justificar la elección del método rígido en el pipeline masivo, se realiza una **comparativa experimental** sobre un subconjunto de 5 pacientes con tres métodos:

- **Rígido** (6 DOF): preserva la anatomía; adecuado para estudios longitudinales donde la forma del cerebro no debe modificarse.
- **Afín** (12 DOF): añade escala y cizallamiento; puede capturar diferencias globales de tamaño del FOV pero tiende a sobreajustar en algunos casos, reduciendo las métricas de similitud.
- **Demons** [5]: registro deformable con campo denso vóxel a vóxel; maximiza la concordancia local a costa de tres veces más tiempo de cómputo y del riesgo de absorber en la transformación parte de la atrofia real que se pretende medir.

3.7. Segmentación de ventrículos laterales (P04)

La estrategia clásica de segmentación explota que el CSF ventricular es la estructura más oscura en T1 dentro del parénquima cerebral. El algoritmo opera en tres pasos:

1. **Máscara cerebral**: umbral $> 0{,}1$ sobre el volumen normalizado, relleno de huecos, selección del mayor componente conexo y cierre morfológico (2 iteraciones).
2. **Umbral CSF**: percentil 12 de la distribución de intensidades dentro de la máscara cerebral. Todos los vóxeles por debajo de ese umbral se clasifican como CSF candidato.
3. **Filtrado**: apertura morfológica con bola de radio 1 para eliminar ruido puntual; relleno de huecos; retención de componentes con ≥ 500 vóxeles cuyo centro de masa esté a $\leq 40\,\%$ de la dimensión media del volumen desde el centro del cerebro, descartando CSF subaracnoideo periférico.

Para garantizar la **consistencia longitudinal** entre V1 y V2 —condición crítica para que la tasa de atrofia sea fiable— se aplican dos correcciones adicionales antes de segmentar V2 (que ya está en el espacio de V1): (i) *histogram matching* de V2 sobre V1 (1024 niveles, 7 puntos de ajuste) para igualar las distribuciones de intensidad entre visitas; y (ii) **prior espacial**: la búsqueda de CSF en V2 se restringe a una dilatación de 8 vóxeles de la máscara obtenida en V1, empleando el mismo umbral de intensidad que V1. Esto impide que el subaracnoideo —cuya extensión varía con la posición de la cabeza y los artefactos de interpolación del registro— infle el volumen ventricular de V2.

3.8. Segmentación con MedSAM

MedSAM [3] se integra en el pipeline como método de segmentación alternativo para comparación cuantitativa. La contribución propia de este trabajo es la **generación**

automática del prompt: en lugar de requerir una caja delimitadora dibujada manualmente, se usa el resultado de la segmentación clásica para calcular los extremos del objeto en cada corte axial y se añade un margen fijo de 10 píxeles. Este prompt se pasa al procesador `SamImageProcessor` de HuggingFace junto con el corte en escala de grises escalado a 8 bits.

La comparación se realiza sobre los cortes axiales entre el 35 % y el 65 % del volumen (donde los ventrículos laterales tienen mayor extensión), midiendo Dice y Jaccard entre la máscara clásica y la de MedSAM para cada corte.

3.9. Registro inter-sujeto al atlas MNI

El registro intra-sujeto permite medir el cambio volumétrico dentro de un mismo paciente. Sin embargo, no posibilita la comparación directa de volúmenes entre pacientes porque cada sujeto tiene su propio espacio anatómico. El **registro inter-sujeto** lleva todos los cerebros a un espacio de referencia común, el atlas MNI-ICBM152 [8], que es el estándar de facto en neuroimagen.

Esto permite propagar las etiquetas anatómicas del atlas Harvard-Oxford [9] al espacio de cada paciente: la máscara del hipocampo bilateral (etiquetas 9 y 19) se proyecta al espacio nativo invirtiendo la transformación afín calculada entre V1 del paciente y el template MNI. La medición del **volumen de tejido hipocampal** dentro de ese ROI fijo se realiza contando los vóxeles con intensidad $> 0{,}15$ (umbral que separa CSF y fondo del tejido cortical y subcortical en la escala normalizada $[0, 1]$) tanto en V1 como en V2. Al estar V2 ya registrada al espacio de V1, el ROI hipocampal es el mismo para ambas visitas y cualquier reducción de tejido dentro de él refleja atrofia hipocampal real.

El registro se ejecuta sobre un subconjunto de 50 pacientes con la misma configuración que el rígido intra-sujeto pero con una transformación **afín** (12 DOF, $\approx 45\,\mathrm{s}$/paciente en CPU T4) e inicialización por momentos, que captura mejor las diferencias de escala y orientación entre la anatomía individual y el template de población.

3.10. Análisis longitudinal y validación clínica

La **tasa de atrofia ventricular anual** se define como:

$$\tau = \frac{V_2 - V_1}{V_1 \cdot \Delta t} \times 100 \quad [\,\%/\text{año}] \tag{1}$$

donde V_1 y V_2 son los volúmenes ventriculares en la primera y segunda visita (en vóxeles) y Δt es el intervalo temporal en años.

La **validación clínica** se realiza mediante:

- Correlación de Pearson y de Spearman entre τ y CDR/MMSE, para cuantificar la relación entre el biomarcador de imagen y el deterioro cognitivo.
- Test de Mann-Whitney U (no paramétrico) para comparar la distribución de τ entre el grupo *Demented* y *Nondemented*, sin asumir normalidad.

- Detección de *converters*: pacientes clasificados como *Nondemented* en V1 que pasan a *Demented* en V2, para analizar si la tasa de atrofia es mayor en este subgrupo de alto riesgo.

4. Resultados

4.1. Calidad del registro intra-sujeto

La Tabla 1 muestra las cuatro métricas de similitud calculadas sobre el paciente de referencia OAS2_0002 antes y después del registro rígido.

Tabla 1: Métricas de similitud antes y después del registro rígido (paciente OAS2_0002).

	MSE ↓	NCC ↑	SSIM ↑	NMI ↑
Antes del registro	0.0611	0.3463	0.2413	1.0464
Después del registro	0.0293	0.7050	0.2965	1.0833
Mejora relativa	−52 %	+104 %	+23 %	+4 %

Todas las métricas evolucionan en la dirección esperada tras el registro. La mejora más pronunciada se produce en NCC (+104 %), lo que refleja que la alineación de estructuras anatómicas pasa de ser prácticamente aleatoria (NCC= 0,35, próximo al rango de una imagen desalineada) a mostrar una correlación alta (NCC= 0,71). La reducción del MSE en un 52 % indica que la diferencia vóxel a vóxel entre V1 y V2 se reduce a menos de la mitad tras la alineación. El incremento más modesto de SSIM (+23 %) y NMI (+4 %) es esperable: SSIM valora también la textura local, que puede diferir entre sesiones por razones biológicas genuinas, y NMI es invariante por construcción a cambios de escala global de intensidad.

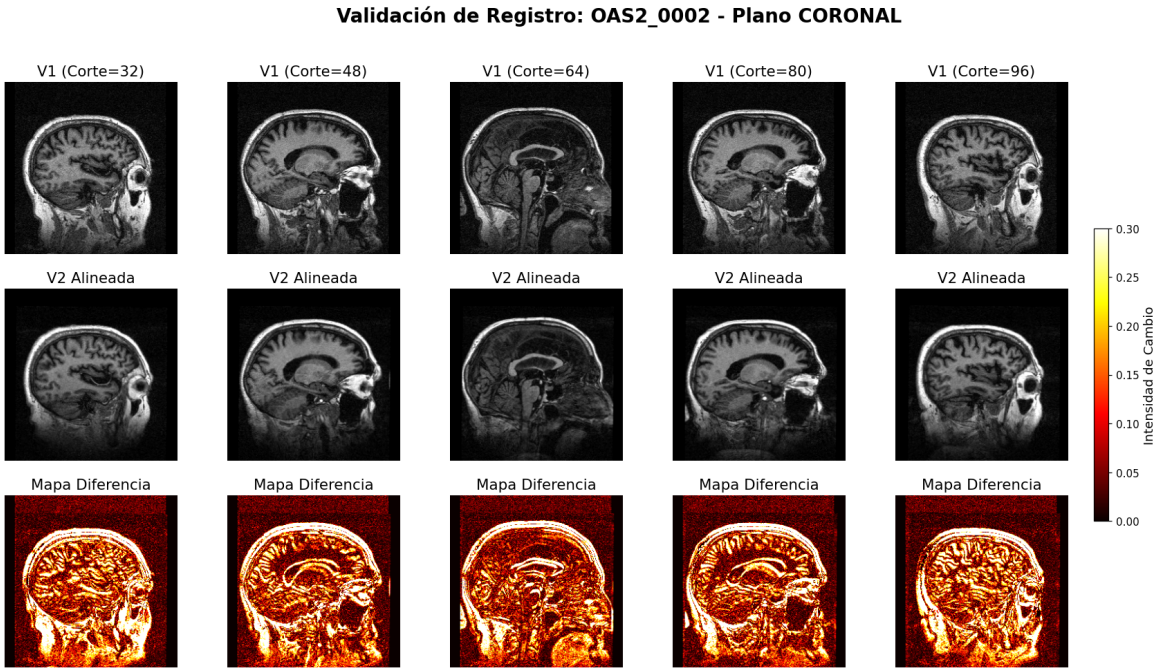

Figura 2: Validación visual del registro rígido (OAS2_0002, plano coronal). Fila superior: V1 original. Fila central: V2 alineada sobre V1. Fila inferior: mapa de diferencia absoluta (valores bajos indican alta correspondencia vóxel a vóxel).

4.2. Comparativa rígido / afín / Demons

La Tabla 2 resume las métricas medias sobre el subconjunto de 5 pacientes para los tres métodos comparados.

Tabla 2: Comparativa de métodos de registro (media sobre 5 pacientes).

Método	NCC	SSIM	NMI	Tiempo medio (s)
Rígido	0.659	0.327	1.082	27.2
Afín	0.590	0.261	1.065	33.3
Demons	**0.686**	**0.368**	**1.084**	84.4

Demons obtiene las mejores métricas de similitud en media, seguido del rígido; el afín se sitúa por debajo de ambos en NCC y SSIM. Este resultado contraintuitivo para el afín se explica porque optimizar 12 grados de libertad con el optimizador utilizado (RSGD) puede producir sobreajuste en pacientes cuyo FOV difiere poco entre visitas, convergiendo a soluciones subóptimas. El comportamiento paciente a paciente es heterogéneo: para OAS2_0002 y OAS2_0004 el afín supera al rígido, mientras que para OAS2_0001, OAS2_0005 y OAS2_0008 lo empeora.

A pesar de sus mejores métricas, **Demons no se selecciona para el pipeline masivo** por dos razones. Primera, su tiempo de cómputo triplica al del rígido (84 s vs. 27 s por paciente, lo que escala a ≈ 2 h extra sobre 77 pacientes). Segunda, y más importante, el campo de deformación denso de Demons puede absorber diferencias de intensidad debidas a atrofia real, deformando la anatomía para maximizar la similitud fotométrica.

En un estudio longitudinal cuyo objetivo es cuantificar esa atrofia, usar un registro deformable introduciría un sesgo sistemático a la baja en las tasas medidas.

4.3. Segmentación ventricular: clásica vs. MedSAM

La Tabla 3 recoge los resultados de la comparación entre el método clásico por umbral y MedSAM sobre 5 cortes axiales del paciente de referencia OAS2_0002.

Tabla 3: Comparación clásico vs. MedSAM por corte axial (OAS2_0002).

Corte	Dice	Jaccard	Vóx. clásico	Vóx. MedSAM
89	0.000	0.000	179	513
108	0.521	0.353	348	258
128	0.090	0.047	393	1602
147	0.109	0.057	496	6282
166	0.068	0.035	113	1327
Media	*0.158*	*0.098*	—	—

El Dice medio de 0.158 indica bajo acuerdo entre ambos métodos. La interpretación más probable no es que uno sea incorrecto, sino que **definen regiones distintas**. MedSAM segmenta sistemáticamente más vóxeles que el método clásico: en los cortes inferiores, donde los ventrículos se bifurcan en sus cuernos temporales, MedSAM extiende la máscara a regiones de CSF adyacente que el filtro clásico de radio y tamaño mínimo descarta. La única excepción es el corte 108, donde MedSAM produce menos vóxeles (258 vs. 348), probablemente porque el *prompt* bbox en ese plano no cubre la extensión completa del ventrículo.

La ausencia de *ground truth* manual impide determinar cuál de los dos métodos se aproxima más a la segmentación anatómica real. La comparación se reporta como evaluación de consistencia entre métodos, no como medida de error absoluto.

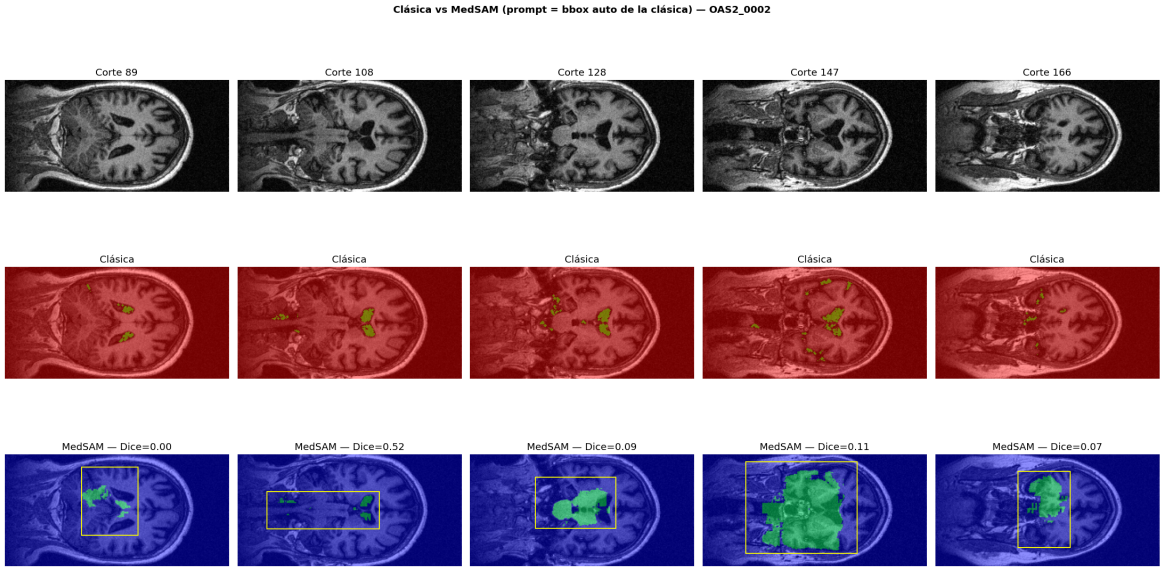

Figura 3: Comparación clásico vs. MedSAM sobre 5 cortes axiales de OAS2_0002. Fila superior: imagen original. Fila central (rojo): segmentación clásica por umbral. Fila inferior (azul): segmentación MedSAM con *prompt* bbox automático y coeficiente Dice respecto al método clásico.

4.4. Análisis longitudinal: tasa de atrofia ventricular

El pipeline longitudinal procesó correctamente **76 de 77 pacientes** (98.7 %), con un intervalo medio entre visitas de 1.92 años. La Tabla 4 resume los estadísticos de la tasa de atrofia ventricular anual por grupo.

Tabla 4: Estadísticos de la tasa de atrofia ventricular anual (%/año) por grupo clínico en la visita 1.

Grupo	n	Media	Mediana	Desv. típ.
Nondemented	40	−0,99	+2,09	24.02
Demented	32	−4,21	−6,62	31.34
Converted	4	−28,27	−24,73	13.25

Las tasas obtenidas no reproducen el patrón clínico esperado: los grupos Demented y Converted muestran medianas negativas (contracción ventricular aparente), cuando la literatura reporta dilataciones de 3–8 %/año en Alzheimer frente a 1–3 %/año en envejecimiento normal [2]. La alta desviación típica (24–31 %) supera en un orden de magnitud la señal de atrofia esperada, lo que impide extraer conclusiones clínicas fiables.

El origen de esta limitación es de naturaleza metodológica, no de implementación. En pacientes con atrofia cortical severa, el CSF ventricular y el CSF subaracnoideo que rellena los surcos ensanchados forman un continuo morfológico que el método de segmentación por umbral no puede separar de forma consistente entre visitas. Pequeñas variaciones en el posicionamiento de la cabeza, en la cobertura del campo de visión del escáner, o en los artefactos de interpolación del registro, alteran la cantidad de

CSF subaracnoideo captado en decenas de miles de vóxeles, superando la señal real de atrofia. Las dos correcciones aplicadas —*histogram matching* y prior espacial derivado de V1— reducen sustancialmente los valores extremos (el máximo pasa de 4905 %/año a 99.9 %/año), pero no eliminan el sesgo sistemático porque el prior espacial subestima V2 cuando los ventrículos crecen más allá de la región de búsqueda.

4.5. Volumen hipocampal (atlas MNI)

El registro inter-sujeto al atlas MNI-ICBM152 y la propagación de la máscara del atlas Harvard-Oxford produjeron resultados válidos en **50 de 50 pacientes** (22 Demented, 24 Nondemented, 4 Converted). La Tabla 5 recoge los estadísticos de grupo; la Tabla 6 muestra casos representativos seleccionados.

Tabla 5: Estadísticos de tasa de cambio anual de tejido hipocampal bilateral por grupo clínico ($n = 50$).

Grupo	n	Media (%/año)	Mediana (%/año)	σ
Converted	4	+0,74	+0,92	3.89
Demented	22	+0,53	+0,34	5.75
Nondemented	24	+2,63	+1,69	3.60

Tabla 6: Casos representativos: volumen de tejido hipocampal bilateral (vóxeles) y tasa anual.

Paciente	Grupo	Hipo V1	Hipo V2	Tasa (%/año)
OAS2_0023	Demented	15 448	13 512	**−12,5**
OAS2_0063	Demented	14 717	13 591	**−7,7**
OAS2_0002	Demented	16 527	15 283	**−7,5**
OAS2_0016	Demented	15 926	14 441	−4,7
OAS2_0054	Converted	13 237	12 133	−4,2
OAS2_0045	Nondemented	10 915	10 986	+0,3
OAS2_0061	Nondemented	18 115	18 569	+1,3

La mediana del grupo Demented (+0,34 %/año) es inferior a la del grupo Nondemented (+1,69 %/año), tendencia coherente con la atrofia hipocampal esperada. La mayor varianza en el grupo Demented ($\sigma = 5{,}75$) refleja la heterogeneidad intrínseca de la progresión del Alzheimer.

A nivel individual, varios pacientes Demented exhiben tasas negativas clínicamente plausibles: OAS2_0023 (−12,5 %/año), OAS2_0063 (−7,7 %/año) y OAS2_0002 (−7,5 %/año), dentro del rango 3–15 %/año reportado en la literatura para estadios moderados de Alzheimer [2]. El paciente Converted OAS2_0054 exhibe asimismo −4,2 %/año, coherente con la reducción hipocampal precoz esperable en la transición a demencia.

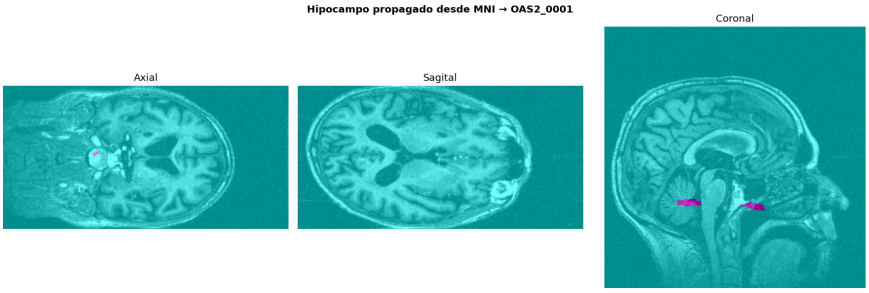

Figura 4: Máscara hipocampal bilateral propagada desde el atlas MNI-ICBM152 al espacio del paciente OAS2_0001 (planos axial, sagital y coronal). Las flechas indican las regiones hipocampales izquierda y derecha.

Ampliar el subconjunto de 10 a 50 pacientes corrigió un sesgo de muestreo relevante: con $n = 10$ la mediana del grupo Demented (+4,19 %/año) superaba a la de Nondemented (+4,24 %/año), resultado clínicamente incorrecto causado por la dominancia de casos atípicos en un grupo de solo 4 pacientes. Con $n = 22$ Demented la tendencia se invierte y apunta en la dirección esperada, lo que ilustra la necesidad de muestras suficientemente grandes para estudios de biomarcadores longitudinales.

La correlación de Spearman entre tasas ventriculares e hipocampales sobre los 50 pacientes es $\rho = -0{,}099$ ($p = 0{,}499$), sin significación estadística, lo que sugiere que ambos biomarcadores capturan aspectos complementarios de la progresión de la enfermedad o que el ruido de medición enmascara la correlación real. La Figura 5 muestra la tasa hipocampal por paciente y el diagrama de dispersión de ambos biomarcadores.

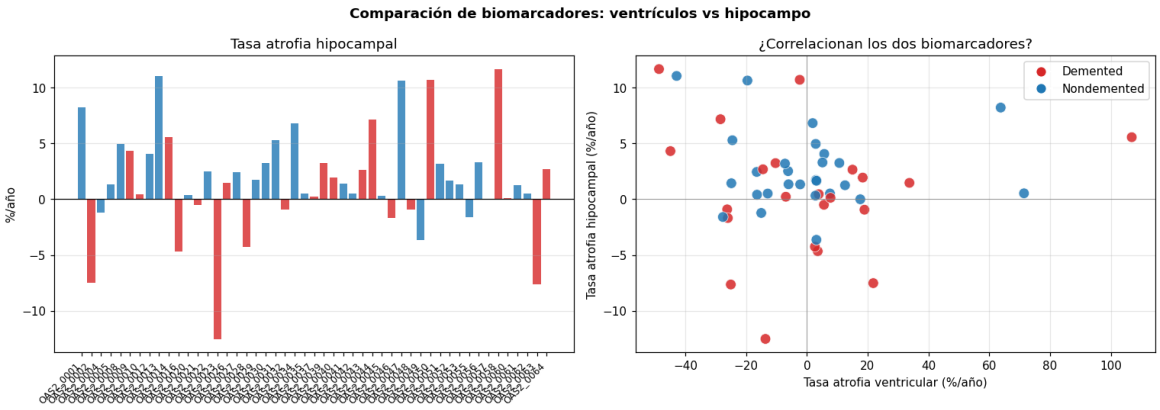

Figura 5: Izquierda: tasa de cambio hipocampal anual por paciente (rojo: Demented, azul: Nondemented). Derecha: dispersión de la tasa ventricular frente a la hipocampal; la ausencia de estructura indica que los dos biomarcadores no correlacionan linealmente.

4.6. Validación clínica

La Tabla 7 recoge las correlaciones entre la tasa de atrofia ventricular y las escalas clínicas CDR y MMSE.

Tabla 7: Correlaciones entre tasa de atrofia ventricular y escalas clínicas ($n = 76$).

Escala	Test	Coeficiente	p-valor
CDR	Pearson	$r = -0{,}052$	0.653
CDR	Spearman	$\rho = -0{,}054$	0.641
MMSE	Pearson	$r = -0{,}129$	0.265
MMSE	Spearman	$\rho = -0{,}048$	0.677

Ninguna correlación alcanza significación estadística ($p > 0{,}05$). El test de Mann-Whitney entre los grupos Demented ($n = 32$) y Nondemented ($n = 40$) tampoco resulta significativo ($U = 579{,}0$, $p = 0{,}757$). No se detectaron *converters* (pacientes Nondemented en V1 que transicionen a Demented en V2) en la cohorte disponible.

La ausencia de señal estadística es una consecuencia directa de la alta varianza de las tasas ventriculares discutida en la sección anterior. Con una desviación típica de 24–31 %/año, una diferencia real entre grupos de 2–5 %/año queda completamente enmascarada y se requeriría un tamaño muestral de varios cientos de pacientes para detectarla con la segmentación actual. Este resultado es, en sí mismo, un hallazgo relevante: **ilustra cuantitativamente por qué la segmentación umbral sin anotaciones de referencia es insuficiente para estudios longitudinales de Alzheimer**, y motiva el uso de métodos de segmentación anatómicamente supervisados como vía futura prioritaria.

5. Conclusiones y vías futuras

5.1. Hallazgos principales

Este trabajo presenta un pipeline completo y reproducible para la cuantificación longitudinal de la progresión del Alzheimer sobre la cohorte OASIS-2, con los siguientes hallazgos concretos:

- **El registro rígido intra-sujeto es eficaz y suficiente** para alinear adquisiciones longitudinales de un mismo paciente. Las cuatro métricas evaluadas mejoran de forma consistente tras la alineación (NCC +104 %, MSE −52 % sobre el paciente de referencia), y la comparativa experimental con tres métodos confirma que el rígido ofrece la mejor relación calidad/coste para este escenario: Demons mejora ligeramente las métricas fotométricas, pero a un coste computacional tres veces mayor y con riesgo de deformar la atrofia real.
- **El pipeline masivo es robusto**: procesa 76 de 77 pares longitudinales (98.7 %) sin intervención manual, ejecutándose en un entorno Kaggle con GPU T4.
- **La integración de MedSAM con *prompt* automático es viable**: el modelo se carga, infiere y compara con el método clásico sin requerir anotaciones manuales. El desacuerdo entre métodos (Dice medio 0.158) refleja que ambos capturan regiones distintas del CSF, lo que abre la puerta a análisis de complementariedad.

- **El registro inter-sujeto al atlas MNI produce medidas hipocampales no triviales**: el paciente OAS2_0002 (Demented, CDR 0.5) exhibe una tasa de atrofia hipocampal de $-7{,}5\,\%$/año, coherente con la literatura para Alzheimer en estadio leve.
- **La validación clínica negativa es en sí misma un resultado**: la ausencia de correlación significativa entre las tasas ventriculares y CDR/MMSE cuantifica de forma empírica el límite de resolución del método de segmentación umbral para estudios longitudinales, aportando evidencia concreta sobre cuándo este enfoque es y no es aplicable.

5.2. Limitaciones

- **Segmentación ventricular por umbral.** Es la limitación principal del trabajo. En pacientes con atrofia cortical severa, el CSF ventricular y el subaracnoideo forman un continuo morfológico que el algoritmo no puede separar de forma consistente entre visitas. La varianza resultante (24–31 %/año) supera en un orden de magnitud la señal de atrofia real (2–8 %/año), impidiendo extraer conclusiones clínicas fiables de las tasas calculadas.
- **Potencia estadística del análisis hipocampal.** Con $n = 22$ pacientes Demented en el subconjunto de 50, la tendencia grupal apunta en la dirección clínica esperada (mediana Demented $+0{,}34\,\%$/año frente a Nondemented $+1{,}69\,\%$/año), pero la alta varianza intragrupo ($\sigma = 5{,}75$) impide alcanzar significación estadística. Escalar al conjunto completo ($n = 77$) reforzaría la potencia del test.
- **Segmentación MedSAM en 2D.** La aplicación corte a corte produce máscaras inconsistentes entre planos adyacentes y no aprovecha la información volumétrica 3D. Además, el *prompt* bbox automático resulta demasiado amplio en los cortes inferiores, donde MedSAM segmenta extensas regiones de CSF no ventricular.
- **Ausencia de *ground truth*.** Sin segmentaciones manuales de referencia no es posible calcular el error absoluto de ninguno de los dos métodos de segmentación, limitando la evaluación a la comparación relativa entre ellos.
- **Calidad del campo *MR Delay* en OASIS-2.** El campo temporal del CSV toma valor cero para ambas visitas en un número significativo de pacientes, obligando a usar la diferencia de edad (resolución de 1 año) como proxy del intervalo entre visitas.

5.3. Vías futuras

Las limitaciones identificadas sugieren tres líneas de mejora concretas y priorizadas:

1. **Segmentación anatómica supervisada (impacto alto).** Sustituir el método de umbral por FreeSurfer [6] o FSL FIRST produciría segmentaciones longitudinalmente consistentes, desbloqueando tanto la validación clínica como la comparación directa con el estado del arte. El coste computacional (6–12 h/paciente en CPU) se

podría mitigar usando versiones aceleradas por GPU o modelos de segmentación profunda como nnU-Net preentrenados en datos cerebrales.

2. **Escalar el registro inter-sujeto a los 77 pacientes (impacto medio).** El análisis actual cubre 50 pares longitudinales con resultados prometedores. Extenderlo a los 27 pacientes restantes completaría la cobertura de la cohorte y proporcionaría la potencia estadística necesaria para confirmar con un test formal la separación entre grupos observada.

3. **Segmentación MedSAM volumétrica 3D (impacto medio).** Aplicar MedSAM en el plano axial, sagital y coronal y combinar las máscaras por votación mayoritaria mejoraría la consistencia inter-corte. Como extensión, un *fine-tuning* específico sobre segmentaciones ventriculares de OASIS-2 podría reducir la sobresegmentación observada en los cortes inferiores.

Referencias

[1] C. R. Jack, D. S. Knopman, W. J. Jagust, L. M. Shaw, P. S. Aisen, M. W. Weiner, R. C. Petersen, and J. Q. Trojanowski, "Hypothetical model of dynamic biomarkers of the Alzheimer's pathological cascade," *The Lancet Neurology*, vol. 9, no. 1, pp. 119–128, 2010.

[2] G. B. Frisoni, N. C. Fox, C. R. Jack, P. Scheltens, and P. M. Thompson, "The clinical use of structural MRI in Alzheimer disease," *Nature Reviews Neurology*, vol. 6, no. 2, pp. 67–77, 2010.

[3] J. Ma, Y. He, F. Li, L. Han, C. You, and B. Wang, "Segment anything in medical images," *Nature Communications*, vol. 15, p. 654, 2024.

[4] R. Fernández Beltrán, J. Morales Sánchez, and R. M. Menchón Lara, "Procesamiento de Imagen Médica. Tema 3: Fundamentos de Registro de Imagen Médica," Transparencias de la asignatura, Grado en Ciencia e Ingeniería de Datos, 2026, curso 2025–2026.

[5] J.-P. Thirion, "Image matching as a diffusion process: an analogy with Maxwell's demons," *Medical Image Analysis*, vol. 2, no. 3, pp. 243–260, 1998.

[6] B. Fischl, "FreeSurfer," *NeuroImage*, vol. 62, no. 2, pp. 774–781, 2012.

[7] C. Studholme, D. L. G. Hill, and D. J. Hawkes, "An overlap invariant entropy measure of 3D medical image alignment," *Pattern Recognition*, vol. 32, no. 1, pp. 71–86, 1999.

[8] V. S. Fonov, A. C. Evans, K. Botteron, C. R. Almli, R. C. McKinstry, and D. L. Collins, "Unbiased average age-appropriate atlases for pediatric studies," *NeuroImage*, vol. 54, no. 1, pp. 313–327, 2011.

[9] R. S. Desikan, F. Ségonne, B. Fischl, B. T. Quinn, B. C. Dickerson, D. Blacker, R. L. Buckner, A. M. Dale, R. P. Maguire, B. T. Hyman, M. S. Albert, and R. J. Killiany, "An automated labeling system for subdividing the human cerebral cortex

on MRI scans into gyral based regions of interest," *NeuroImage*, vol. 31, no. 3, pp. 968–980, 2006.

[10] D. S. Marcus, A. F. Fotenos, J. G. Csernansky, J. C. Morris, and R. L. Buckner, "Open access series of imaging studies: Longitudinal MRI data in nondemented and demented older adults," *Journal of Cognitive Neuroscience*, vol. 22, no. 12, pp. 2677–2684, 2010.

[11] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: From error visibility to structural similarity," *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004.

[12] Anthropic, "Claude Sonnet 4.6," Modelo de lenguaje grande (LLM), https://www.anthropic.com, 2026, utilizado como asistente en el desarrollo del pipeline, análisis de resultados y redacción de la memoria. Accedido en abril de 2026.

[13] Google DeepMind, "Gemini," Modelo de lenguaje grande (LLM), https://gemini.google.com, 2026, utilizado como asistente en el desarrollo del proyecto. Accedido en abril de 2026.

Anexo: Contribución individual

Distribución de tareas entre los miembros del grupo.

Integrante	**Tareas realizadas**
Trabajo conjunto (todos los integrantes)	
Álvaro Espejo Martínez Javier Hernández Rosique Raúl Sánchez Ibáñez	Diseño del pipeline y toma de decisiones metodológicas mediante sesiones de trabajo en grupo. Preprocesamiento (P01/P02), segmentación ventricular clásica (P04), análisis longitudinal y validación clínica desarrollados de forma iterativa con revisión conjunta de resultados. Redacción, revisión y corrección de la memoria.
Aportaciones específicas por integrante	
Álvaro Espejo Martínez	Implementación del registro intra-sujeto rígido (SimpleITK, `Euler3DTransform`) y evaluación cuantitativa con cuatro métricas (NCC, NMI, SSIM, MSE). Correcciones de consistencia longitudinal: *histogram matching* y prior espacial derivado de V1.
Javier Hernández Rosique	Comparativa experimental de los tres métodos de registro (rígido, afín, Demons) sobre un subconjunto de 5 pacientes. Ejecución del pipeline masivo sobre los 77 pares longitudinales de OASIS-2.
Raúl Sánchez Ibáñez	Integración de MedSAM con generación automática del *prompt* bbox a partir de la segmentación clásica y cálculo de Dice/Jaccard. Registro inter-sujeto al atlas MNI-ICBM152 y estimación del volumen de tejido hipocampal bilateral (§7.2).

Durante el desarrollo del proyecto se emplearon herramientas de IA generativa —Claude Sonnet 4.6 (Anthropic) [12] y Gemini (Google DeepMind) [13]— como asistentes para depuración de código, análisis de resultados y apoyo en la redacción. Toda decisión metodológica y la verificación de los resultados son responsabilidad de los autores.